

被排除在外的人

嘉轩卓1、3、4、泽宇陈1、3、4、建煌赖1、2、3*、广聪王1、3、4

1中山大学，广州，中华人民共和国

广州中山大学2信息安全技术广东省重点实验室

4教育部机器智能与高级计算重点实验室

{zuojsx5, chenzy5, wanggc3}@mail2. sysu.edu.cn, stsljh@mail.sysu.edu.cn

ABSTRACT

当应用于拥挤的公共场所时，人的重新识别(re-id)会遇到严重的遮挡问题。在本文中，我们提出了利用具有遮挡的人的图像来检索全身人的图像。这与传统的人再识别问题有很大的不同，在这个问题上，假设人的图像是在没有任何遮挡的情况下被检测到的。因此，我们称这个新问题为被遮挡的人重新识别。为了解决这一新问题，我们提出了一种基于深度学习的人身体注意力框架(AFPB)，包括1)遮挡模拟器(OS)，它自动为全身人图像生成人工遮挡，2)多任务损失，迫使神经网络不仅区分一个人的身份，而且还确定一个样本是来自遮挡数据分布还是全身数据分布。对一个新的遮挡行人重识别数据集和三个现有的基准进行了实验，修改为包括全身人图像和遮挡人图像，表明了该方法的优越性。

指数术语·包括人的重新识别、人的注意框架、遮挡模拟器、多任务损失

1. 导言

人的重新识别(re-id)旨在通过多个非重叠相机重新识别目标人，这已被应用于加强许多重要公共空间的安全，特别是拥挤的公共空间，例如机场、火车站、购物中心和医院。然而，当引导人在这些拥挤的地方重新识别时，遮挡是一个不可避免的问题。例如，一个人/罪犯可能被现场的其他人遮挡，或诸如汽车、柱子、墙壁等静态障碍物。考虑到遮挡问题的重要性，寻找一种有效的方法是至关重要的。



图1：被遮挡者重新标识的插图。左：视频监控中的原始图像；中：被现有行人探测器检测到的遮挡目标人；右：我们的目标是给一个有遮挡的人找回一个全身的人。红色包围框表示同一个人，而绿色表示不同的人。

搜索全身人图像，给出一个人图像与遮挡作为探针（图1）。我们称之为被遮挡的人重新识别问题。

有三个现实的挑战成为解决遮挡行人重识别的瓶颈。首先，遮挡不仅会导致目标信息的丢失，还会导致遮挡信息的干扰。具有不同特征的遮挡，如颜色、大小、形状和位置，会使人的重新标识的全局表示恶化。因此，对于被遮挡的人来说，很难学习到一种鲁棒的特征表示。其次，人们可以对被遮挡的人的图像使用基于局部/部分的表示。一种直观的方法是使用身体部位检测器检测非遮挡的身体部位，然后在画廊中匹配相应的身体部位。然而，身体检测器学习需要额外的注释。更糟糕的是，有时遮挡的身体部位是关键的区别部位，而非遮挡的身体部位则有相似的外观。第三，由于大多数现有的方法隐含地假设一个人的全身外观是现成的，而一个有遮挡的人的图像是一个无效的样本，很少有公共数据集供遮挡行人重识别去学习一个合适的模型，特别是用于深度学习。

*撰写人




图 2：概述我们的做法。给定源图像，我们首先使用遮挡模拟器生成人工遮挡数据，然后将源数据和遮挡数据联合编码到具有多任务损失的CNN网络。

为了解决这一具有挑战性的问题，我们提出了一种新的深度学习框架，称为人体注意力框架 (AFPB) (fig 2)。特别是，AFPB由两个部分组成。首先，使用遮挡模拟器(OS)通过随机添加背景补丁到全身人图像中自动生成大量人工遮挡的人图像。因此，人工遮挡的人的图像是作为一个人工遮挡集形成的。然后，人工遮挡集和源（全身）集被联合使用，以学习被遮挡者重新识别的鲁棒特征表示。第二，多任务损失，即识别损失和遮挡/非遮挡二进制分类(OBC)损失，被整合到AFPB框架中。令人惊讶的是，简单的OBC损失带来了令人印象深刻的改进，通过确定一个样本是来自人工遮挡集还是来自源图像。

通过使用遮挡模拟器模块，AFPB方法可以被描述为一个“注意”模型。与传统的注意方案不同，AFPB框架通过观察OS模块产生的不同类型的遮挡人，逐渐关注人的身体。还可以隐式地将AFPB框架解释为先前知识的编码器，允许将额外的专家知识集成到深度框架中。特别是，AFPB的OS模块通过生成大量人工知识相关样本来模拟现实世界来集成遮挡信息，而OBC损失的目的是确定一个样本是来自被遮挡的人集还是全身人集，从而将先前的信息编码到框架中。此外，识别损失可以区分给定的人的身份，无论该人是否被遮挡。这种限制还迫使框架关注人的身体部分。

该方法可以通过具有反向传播的SGD进行端到端的训练，并且可以很容易地使用公共库(例如Caffe)来实现。综上，本文主要做出三方面的贡献..

- 这是第一次尝试定义遮挡行人重识别问题，这是常见的现实场景和应用。

- 对于被遮挡的人重新识别任务，我们提出了一个个人身注意框架 (AFPB)，它通过观察不同类型的被遮挡者来逐渐关注人的身体。遮挡模拟器(OS)用于生成人工样本来编码先验知识，而多任务损失用于学习针对遮挡问题的鲁棒特征表示。

- 我们创建了一个名为 Occluded-REID的新数据集和两个被修改的数据集 P-DukeMTMC-reID and P-ETHZ，它们分别从 DukeMTMC-ReID[1]和 ETHZ[2]中为遮挡行人重识别。

2. 相关工作

典型人物再识别工作主要包括两个步骤：特征提取和度量学习。第一步旨在提取一种鲁棒和独特的特征表示，它不受光照、视点和遮挡等挑战的影响。第二步学习度量或子空间，以便更好地匹配，从而使同一类的距离比不同类的距离更近。

最近，随着深度学习的发展[3]，有三种网络框架应用于人的再ID，即分类网络、暹罗网络和三重态网络。分类网络将人重识别问题视为分类问题，由于卷积神经网络(CNN)在大规模数据集上的优越性能，直接提取判别特征。例如，肖等人。[4]采用域导退(DGD)方法，共同训练多个领域的分类模型，以提高性能。暹罗网络以图像对作为输入，并使用对比损失计算相似性。例如，Ahmed等人。[5]计算图像对的邻域差，以学习指示两个输入图像是否描绘同一个人的度量。三重网络，由于三个输入图像之间的相似性，是一个扩展版本的暹罗网络。基于[6]，Wang等。[7]开发了一个点对集三重态，用于图像到视频的人物重识别。

虽然人物重识别方法已经得到了很好的研究[4-11]，但很少有工作初步尝试解决被遮挡人物重识别问题。在与我们有相似想法的作品中，部分人重新识别[12]的目的是将探针部分图像与画廊全身图像相匹配，这是为了给遮挡人物重识别问题提供一张图片。然而，他们只关注非遮挡的身体部分和全身部分之间的匹配..一些关键问题仍然需要解决：1)现有的行人探测器对被遮挡的人的图像的输出往往包括人的身体的一部分和其他遮挡，而不仅仅是部分身体。也就是说，在[12]中，必须通过手工裁剪操作来消除遮挡，即

在实践中不现实；2)[12]中提出的基于补丁的匹配方法需要大量的计算，而不考虑注意方案。我们基于CNN网络的工作不同于[12]，因为我们直接计算被遮挡的人图像和全身人图像之间的匹配，并提出了一个AFPB框架，通过观看由操作系统生成的各种被遮挡的人数据来自动关注人的身体。

3. 方法

我们提出了一个深度学习框架，人的身体注意力框架(AFPB)，如图所示。2. AFPB包括两个主要组成部分：遮挡模拟器(OS)和多任务损失。该遮挡模拟器旨在生成人工遮挡数据，使用源(全身人)数据模拟各种遮挡情况。接下来，在CNN网络上对全身人数据和遮挡人数据进行多任务损失联合训练，即识别损失和遮挡/非遮挡二值分类(OBC)损失。通常，AFPB通过将遮挡的先验信息编码到框架中，迫使特征表示更多地关注人的身体部分。在本节中，我们详细介绍了这些阶段，并可视化了注意结果。

3.1. 遮挡模拟器(OS)

正如第1节中提到的，随着被遮挡者重新识别数据不足的限制，很难为遮挡人物重识别训练一个合适的深度模型。人们会想，是否可以根据现有数据创建大量被遮挡的人重识别数据。这个问题的一个好主意是从全身人数据中自动生成人工遮挡的人数据。这样，不仅可以模拟多种遮挡情况，而且可以给整个系统带来多样化的信息。基于上述假设，我们设计了一个遮挡模拟器(OS)来生成人工遮挡的人图像。接下来，我们联合训练一个CNN网络基于源/全身人数据和被遮挡的人数据。该网络将更多地关注人的身体部位，通过观看各种遮挡的人的图像在人物重识别。具体实施如下：

假设我们有一个原始的全身数据集X，它由M个身份的N个图像组成。

{1, 2, ..., M}是标识。遮挡模拟器可以表示为图像映射函数 $F: X \rightarrow Z$ ，其中Z是从真实图像集X生成的人工遮挡数据集。映射F是通过一种简单但有效的方法来实现的，其中来自源图像背景的随机补丁被用作遮挡来覆盖人身体的一部分。设 $\{(z_i(j), y_i) | j=1 \dots N, i=1 \dots M\}$ 表示Z中的所有样本，其中 $z_i(j)$ 是

从 x_i 生成的JTH人，我们最终将X和Z合并成一个组合集。该过程如算法1所示。

算法1：遮挡模拟

输入：全身集合X(有N个真实图像)
背景贴片的尺寸
闭塞面积比范围[r1, r2]

输出：人工遮挡集Z，合并集O，而N>0做

- 1
- 2 从X中随机选择一个带有标签y的图像I，选择一个
- 3 遮挡区域，所以 $[S1 \times r1, S1 \times r2]Sb=s \times s$ 从I中选
- 4 择一个背景贴片
- 5 Sb
- 6 i, i, i, i, i, i, i, i的随机位置被覆盖，所
- 7 以，把i, i, i, i, 带标签, y, y, 设置Z
- 8 $N \leftarrow N - 1$
- 9 结束
- 10 组合集合O、B组合集合X和集合Z

我们的目标是学习一个通用的特征提取器 $h(\cdot)$ ，它使同一个人的描述符更接近，而不同的描述符更不同。在我们的框架中，我们训练一个具有识别损失的CNN来识别每个人的身份。当只对全身集合X进行训练时，目标函数是

$$\arg \min_{f, h} \sum_{i=1}^M \sum_{j=1}^N L^P(f(h(x_i^{(j)})), y_i) \quad (1)$$

其中 $f(\cdot)$ 是亲自识别分类器， $LP(\cdot)$ 是识别损失函数。在从X生成人工遮挡集Z后，我们将两个集合组合在一起，因此目标函数是

$$\arg \min_{f, h} \sum_{i=1}^M \sum_{j=1}^N L^P(f(h(x_i^{(j)})), y_i) + \sum_{i=1}^M \sum_{j=1}^N L^P(f(h(z_i^{(j)})), y_i) \quad (2)$$

可以看出，目标函数使 $h(x_i)$ 和 $h(z_i)$ 都更接近 y_i ，因此它会迫使 $h(z_i)$ 与 $h(x_i)$ 更相似。直观地解释说，网络已经学会了如何通过观看大量被遮挡的人的数据和源数据来更多地关注关键的人的身体部位，而不是遮挡或背景。

3.2. 多任务损失

随着识别损失，使用闭塞/非闭塞二进制分类(OBC)来确定样本是来自闭塞的人分布还是全身人分布，这样我们的框架就可以在区分一个人的身体是否被遮挡的基础上识别出这个人。当将两个损失集成到一个统一的框架中时，进一步学习AFPB方法提取一个

被遮挡的人的鲁棒和鉴别特征表示。这样，OBC丢失将先前的遮挡信息编码到框架中。

我们将人员重新ID视为分类问题，并使用Softmax损失作为识别损失。假设原全体集具有K恒等式，给出了一个K类Softmax损失的人重新ID分类器。

$$L^P(\hat{y}_i, y_i) = \sum_{k=1}^K \{y_i = k\} \log \frac{e^{y_{k,i}}}{\sum_{k=1}^K e^{y_{k,i}}} \quad (3)$$

其中 $y_{k,i}$ 是k类的ith训练样本的re-id分类器的预测分数。因此，OBC损失是由

$$L^O(\hat{y}_i, y_i) = \sum_{c=0}^C \{y_i = c\} \log \frac{e^{\hat{y}_c}}{\sum_{c=0}^C e^{\hat{y}_c}} \quad (4)$$

其中 $y_{conveni}$ 是第i个训练样本的遮挡分类器中的预测分数， $c \in \{0, 1\}$ 其中 $c=0$ 表示被遮挡者， $c=1$ 表示未被遮挡者。将识别损失和OBC损失相结合，将多任务损失表述为

$$L = \alpha L^P(\hat{y}_i, y_i) + (1 - \alpha) L^O(\hat{y}_i, y_i) \quad (5)$$

其中， $\alpha \in (0, 1)$ 是一个超参数，它平衡了两个各自的损失。一般来说，由于LP(icon)的存在，所以设置 $\alpha=0.5$ 是合理的。

对LP的帮助(具有多任务损失，CNN网络具有识别该人的判别性，无论一个人是否被遮挡。也就是说，如果一个全身的人图像是可利用的，网络可以利用整个人的结构信息。如果一个人被遮挡，网络可以集中在关键的身体部位。

通过这个过程，我们的框架可以集中在人的身体部分，以学习一个鲁棒的特征表示，在真实的world.Fig.3显示显著性映射，通过平均汇集所有特征映射的最后一个卷积层。这证明了我们的框架可以更多地关注人的身体部位，而不是遮挡或背景。

4. 经验

4.1. 安装程序

数据集。我们在四个数据集上对所提出的方法进行了评估：封闭-REID、部分-REID、P-DukeMTMC-REID和PET HZ，每个数据集被组织成两个部分：被遮挡的人图像和全身人图像（见图）。4）。遮挡-REID数据集是一种由移动摄像机设备捕获的新数据集，由200个被遮挡者的2000张图像组成。每个身份有5个全身人像和5个不同类型重度闭塞人像

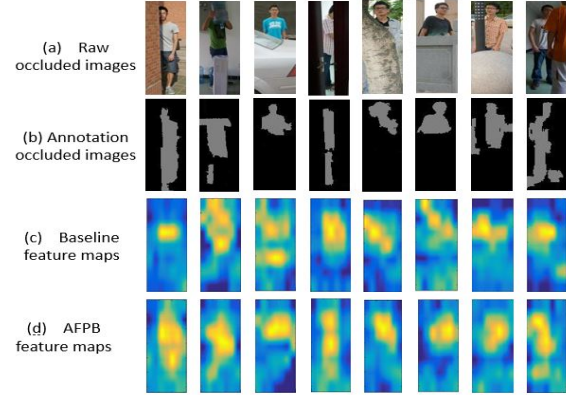


图 3：例子：(a)原始闭塞图像，(b)人工标注人体部位的闭塞图像，(c)基线网络的显著性地图，(d)AFPB的显著性地图。突出区域揭示了网络表示关注的部分。

遮挡物。所有具有不同观点和背景的图像都被调整为 128×64 。此数据集将在稍后发布。

从DukeMTMC-ReID数据集[1]和ET HZ数据集[2]中修改了P-DukeMTMC-ReID数据集和P-ET HZ数据集。它们包含在公共场合被不同类型的遮挡遮挡的目标人的图像，例如人、行李、汽车和导板。我们选择具有全身人图像和闭塞人图像的身份。整理后，在PDukeMTMC-reID中有24143张1299ID的图像，在P-ET HZ中有3897张85ID的图像。这两个数据集也将在稍后发布。部分-REID数据集是部分人的第一个数据集[12]，其中包括900幅60人的图像，其中5幅全身人图像、5幅部分人图像和5幅被遮挡的人图像。这些图像是在一个大学校园收集的，有不同的观点和遮挡。实验环境。我们以被遮挡的人的图像为探针，以全身人的图像为画廊，随机选择一半的身份进行训练，其余的进行测试。我们报告了在基线网络ResNet-50[13]上训练的结果。单次($N=1$)和多次($N=2, 3, 4, 5$)实验的初始学习率为 $1e-3$ ，批大小 $=20$ ， $\beta=0.8$ ，迭代50K。评价指标。在匹配生成中，我们通过L2距离计算每个探针与所有画廊图像之间的相似性。广泛应用的累积匹配特性(CMC)曲线[7]和秩-1率被用来定量评价人的再ID任务。实验重复10次，以获得平均结果。

数据增强。在我们的实验中，我们将所有的图像调整为 240×240 ，并用一个小的随机扰动裁剪 224×224 的中心区域来增加训练数据。



图 4：数据集实例。上：闭塞人影像；下：全身人影像..

4.2. AFB框架的执行情况

为了评估我们的人身注意力框架 (AFB) 的性能，我们将其与三个网络进行了比较：1) 基线网络，在大规模的人再ID数据集 MA RS[14] 上获得的 ResNet-50，2) 具有 AFB 第一个组成部分的基线网络，遮挡模拟器 (OS)，3) 具有 AFB 第二个组成部分的基线网络，多任务损失，在四个数据集上，Occluse-REID，部分 REID，PD-MC-re-ID 和 ETH。如表 1 和图所示。我们的 AFB 框架显著优于基线大幅度（分别提高了 10.9%、8.7%、7.0% 和 7.1%），这表明了我们框架的有效性。此外，ResNet-50 与操作系统和多任务损失的性能也优于基线，但比我们的 AFB 框架更差。它表明，框架的两个组成部分对拟议的框架作出了贡献，它可以通过将它们结合在一起来获得更好的性能，因为 AFB 的两个组成部分形成了一种互补关系，以处理各种闭塞的情况。

此外，我们还在两个实验中评估了 AFB 的遮挡意识和注意性能。首先，我们测试了 OBC 在训练模型上的准确性。分类准确率分别为 88.50%、85.33%、91.75% 和 73.88%，分别为封闭 REID、部分 REID、P-DukeMTMC-REID 和 P-ETHZ，表明 OBC 损失对 AFB 有遮挡意识。然后，我们计算检测精度 [15]，这是显着性映射中的显着区域与我们在封闭 REID 和部分 REID 上手动注释身体部分的比率（图）。3)。表 2 显示了我们的方法在检测精度上分别超过基线网络 6.21% 和 7.13%，这证实了 AFB 对人的身体有优势。

4.3. 与最先进的相比

我们在表 3 和图中将我们的方法与最先进的方法进行了比较。6. 我们收集了七种方法

表 1：AFPB 在单次/多次射击中的表现

DATA	方法	N=1			N=2			N=5		
		r=1	r=5	r=10	r=1	r=5	r=10	r=1	r=5	r=10
Occluse-REID	ResNet-50 [13]	57.27	81.40	89.66	76.37	94.43	97.96	90.00	99.00	99.00
	Res Net-50+遮挡模拟器 Res Net-50+多任务损失	63.95	85.62	92.05	82.82	96.34	98.71	90.00	99.00	100.00
	ResNet-50+Ours	68.14	88.29	93.67	86.51	97.26	98.88	94.00	99.00	100.00
	ResNet-50 [13]	69.82	89.68	96.10	84.53	96.45	98.98	90.00	100.00	100.00
部分 REID	Res Net-50+遮挡模拟器 Res Net-50+多任务损失	74.29	92.91	97.69	89.63	98.89	99.69	93.33	100.00	100.00
	ResNet-50+Ours	71.26	89.77	96.37	85.89	96.58	99.00	90.00	100.00	100.00
	ResNet-50 [13]	78.52	94.87	98.03	91.25	99.20	99.77	96.67	100.00	100.00
	ResNet-50 [13]	39.16	57.13	64.35	44.62	63.58	70.73	-	-	-
PD-MC-re-ID	Res Net-50+遮挡模拟器 Res Net-50+多任务损失	40.50	57.73	65.22	46.67	65.27	72.79	-	-	-
	ResNet-50+Ours	39.04	57.21	64.80	45.24	64.37	71.66	-	-	-
	ResNet-50 [13]	46.15	63.47	70.67	51.95	70.40	77.22	-	-	-
	ResNet-50 [13]	51.09	78.54	89.34	53.35	81.34	89.97	53.05	82.88	90.44
P-ETHZ	Res Net-50+遮挡模拟器 Res Net-50+多任务损失	55.48	80.71	90.54	58.42	83.11	91.28	59.96	83.59	91.08
	ResNet-50+Ours	54.97	82.11	90.54	58.88	84.41	91.28	59.76	84.66	91.08
	ResNet-50 [13]	58.15	84.61	92.11	61.31	85.94	92.84	63.55	87.02	93.50
	ResNet-50 [13]	51.09	78.54	89.34	53.35	81.34	89.97	53.05	82.88	90.44

表 2：Occluse-REID 和部分 REID 显着性图中显著区域的检测精度

方法	Occluse-REID	部分 REID
[13] Res Net-50+Ours	77.26% 83.48%	75.07% 82.20%

表 3：1/5/10 等级与最先进水平比较。

DATA	方法	Occluse-REID			部分 REID			P-DukeMTMC			P-ETHZ		
		r=1	r=5	r=10	r=1	r=5	r=10	r=1	r=5	r=10	r=1	r=5	r=10
A	XQDA [16]	36.71	65.11	77.65	33.14	66.18	83.03	15.93	27.50	33.89	44.98	70.88	83.69
	KCVDA [17]	32.48	59.10	71.70	36.20	70.33	85.40	22.18	36.75	44.01	39.45	69.76	83.50
	GOG [18]	40.50	63.16	73.77	41.92	74.00	86.54	17.10	29.27	35.82	49.17	79.29	90.21
	空空 [19]	46.47	75.36	85.37	37.73	72.12	88.26	35.17	53.65	61.85	40.16	71.53	84.42
B	决定指导文件 [4]	41.43	65.74	75.91	56.83	77.70	85.00	41.53	60.09	67.61	51.23	81.01	91.16
	SVDNet [20]	63.13	85.13	92.28	56.05	87.06	94.31	43.47	63.41	71.12	52.21	78.95	87.44
	REDA [21]	65.79	87.88	93.85	76.19	94.57	97.43	45.18	62.88	69.92	54.43	79.09	89.17
	[13] Res Net-50+Ours	57.27	81.40	89.66	69.82	89.68	96.10	39.16	57.13	64.35	51.09	78.54	89.34
C	ResNet-50+Ours	68.14	88.29	93.67	78.52	94.87	98.03	46.15	63.47	70.67	58.15	84.61	92.11
	ResNet-50 [13]	69.82	89.68	96.10	84.53	96.45	98.98	90.00	100.00	100.00	100.00	100.00	100.00
	ResNet-50 [13]	69.82	89.68	96.10	84.53	96.45	98.98	90.00	100.00	100.00	100.00	100.00	100.00
	ResNet-50 [13]	69.82	89.68	96.10	84.53	96.45	98.98	90.00	100.00	100.00	100.00	100.00	100.00

包括 (A) 四种手工制作特征和距离度量的方法和 (B) 三种基于深度学习的方法。显然，我们的方法在所有类别中表现最好，在排除 -REID、部分 -REID、P-DukeMTMC-ReID 和 P-ETHZ 上分别超过排名 -1 的第二名，分别为 2.35%、2.33%、0.97% 和 3.72%。一般来说，(B) 中方法的性能优于 (A) 中的方法，因为深度神经网络具有强大的学习能力来自动学习和更新模型。在 (B) [4] 中的一些方法不表现出良好的性能，因为它们的模型关注的是具有全身图像的数据，而不考虑被遮挡的数据域。不同的是，我们的方法可以学习确定一个人是否被遮挡，并基于遮挡的先验知识提取健壮的特征表示。通过这种方式，我们的方法显示了在被遮挡的人重新 id 中的优势..

4.4. 参数分析

我们模型中唯一的一个参数 控制了识别损失和 OBC 损失之间的权衡。为了探讨两种损失的不同比例的影响，我们进一步测试了不同 在 Occluse-REID 和部分 REID 上的表现。如图所示。随着 的增加，表示的性能提高。

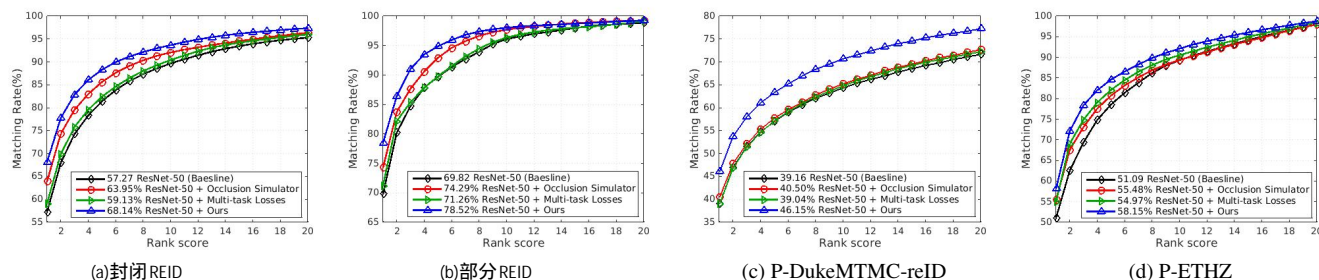


图 5：CMC曲线和秩-1率与基线的比较。

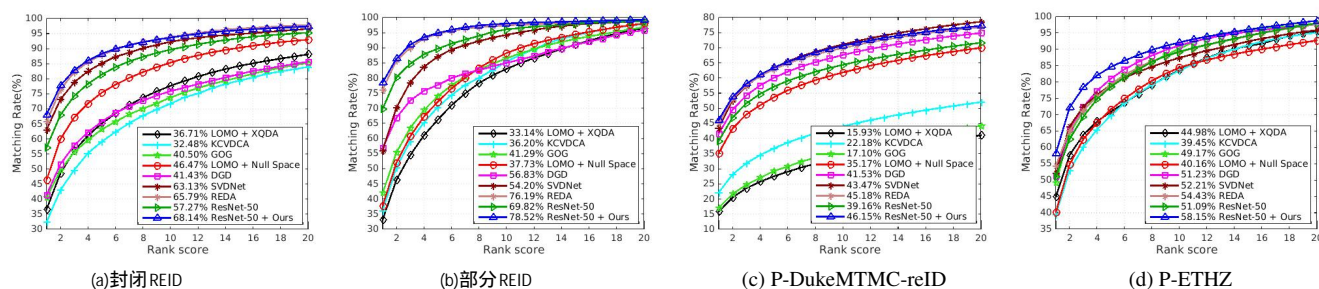


图 6：与最先进的CMC曲线和秩-1率的比较。




图 7：在不同的 Occlusion-REID和部分REID上的单射和多射实验的秩-1率。

当在0.7和0.9以内时，我们的模型达到了更好的性能，这证实了OBC损失的辅助效果。

5. 结论

在本文中，我们第一次尝试解决被遮挡的人重新id问题。为解决这一问题，提议设立菲律宾武装部队通过观看各种生成的被遮挡的人图像来学习健壮的特征表示。此外，多任务损失被纳入个人主体注意的框架。实验结果表明了该方法的有效性和优越性。

这个项目是支持的 by * 自然科学基金委(U161573387)。

6. 参考资料

- [1] Z.郑先生、郑先生和杨先生，“GAN产生的无标记样本改善了人的体外再鉴定基线”，2017。
- [2] A.Ess, B.Leibe, K.Schindler, 和L.Van Gool, “鲁棒多人跟踪系统”，在CVPR，2008年。

- [3] G.Wang, X.H.Xie, J.H.Lai, 和J.X.卓, “深度成长学习”，载于ICCV，2017年。
- [4] T.Xiao, H.S.Li, W.L.欧阳, 和X.G.Wang, “学习深度特征表示与领域引导辍学的人重新识别”，在CVPR，2016。
- [5] E.Ahmed, M.Jones和T.Marks, “一个改进的人再识别的深度学习架构”，载于CVPR，2015年。
- [6] S.Ding, L.Lin, G.R.Wang, 和H.Y.Chao, “深度特征学习与相对距离比较的人再识别”，PR，2015。
- [7] G.Wang, J.H.Lai, 和X.H.Xie, “P2snet: 图像能匹配吗？以端到端的方式重新识别别人的视频？”，TCSVT, 2017。
- [8] Y.Chen, X. T.Zhu, W.S.Zheng, 和J.H.Lai, “通过相机相关感知特征增强的人的重新识别”，TPAMI，2018。
- [9] S.Chen, C.C.Guo, 和J.H.Lai, “通过联合表示学习进行人的重新识别的深度排名”，TIP，2016。
- [10] S.石建中, 郭文华, 赖志华, 陈S.陈振中, 胡新杰, “人与多层次自适应对应模型的再识别”，神经计算，2015年。
- [11] C.郭、陈、黎、胡、史C, “多镜头人的重新识别与自动模糊推理与去除”，载于2014年全面政策审查。
- [12] W.郑先生、李先生、翔先生、廖先生、黎先生、龚先生, “部分人的重新鉴定”，载于ICCV，2015年。
- [13] K.何明明, 张学英, 任国强, J.太阳, “图像识别的深度残差学习”，在CVPR，2016。
- [14] L.Zheng, Z.Bie, Y.F.Sun, J.D.Wang, C.Su, S.J.Wang, 和Q.Tian, “Mars: 一个大规模人重新识别的视频基准”，载于ECCV，2016年。
- [15] A.Borji, M.M.Cheng, H.Jiang, 和J.Li, “显著的目标检测：一个基准”，TIP，2015。
- [16] S.C.Liao, Y.Hu, X.Y.Zhu, 和S.Z.Li, “通过局部最大发生表示和度量学习的人再识别”，载于CVPR，2015年。
- [17] Y.Chen, W.S.Zheng, 和J.H.Lai, “Mirror Representation for modeling view-specific transform in person-re-identification”，in IJCAI，2015。
- [18] T.Matsukawa, T.Okabe, E.Suzuki, 和Y.Sato, “《人的重新识别的层次高斯描述符》，载于CVPR，2016年。
- [19] L.Zhang, T.湘, 和S.G.龚, “学习一个歧视性的人重新识别的空间”，见CVPR，2016。
- [20] Y.Sun, L.Zheng, W.J.Deng, 和S.J.Wang, “Svdnet用于行人检索”，arXiv预印arXiv: 1703.05693, 2017。
- [21] Z.Zhong, L.Zheng, G.L.Kang, S.Z.Li, 和Y.Yang, “随机擦除数据增强”，arXiv预印arXiv: 17080896, 2017。